Raport projektu: Porównanie metod klasteryzacji w pakietach Python

Cel projektu
Podczas projektu zostały użyte następujące metody klasteryzacji: K-means, Agglomerative, DBSCAN z pakietu sklearn.cluster. Metody klasteryzacji zostały wyćwiczone na następujących zbiorach danych: Wine, Yelp Restaurant Reviews.csv, Iris. Podczas projektu użyto następujące metryki do mierzenia rozłożenia próbek w klastrze: Silhouette Score, Davies-Bouldin Score, Calinski-Harabasz Index. Wczytane dane zostały przygotowane do użycia z odpowiednim modelem oraz zostało dokonane EDA. Przygotowano również wykresy, które pomogą w zrozumieniu danych i uczenia. Zostały również zmierzone różne metryki w celu ewaluacji modelu.
W projekcie użyto następujące zbiory danych:

- Wine
- Iris
- Yelp Restaurant Reviews.csv

Zbiór Wine
Zbiór danych Wine to zbiór danych opisujący wyniki analizy chemicznej win. Zbiór danych zawiera 178 instancji reprezentujących różne wina. Każda instancja opisana jest przez 13 atrybutów.
Badana kolumna ‘target’ ma 3 klasy. Równowaga klasowa jest delikatnie zaburzona.

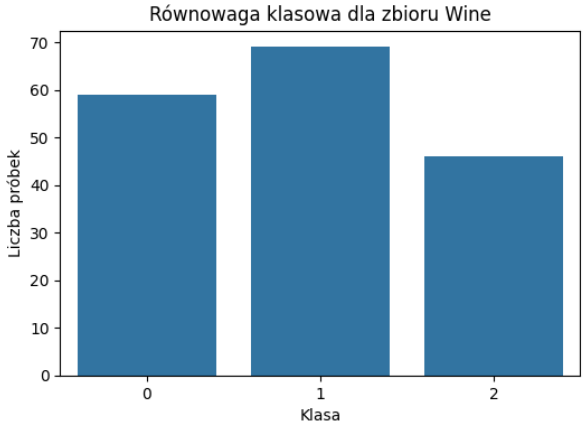

Zbiór Wine - EDA

Podmieniono wartości NA na średnią kolumny funkcją do tego przeznaczoną. Usunięto duplikaty Zamieniono próbki odstające (outliers) na średnią kolumny. Dokonano normalizacji - użyto skalera Standard Scaler z sklearn. Usunięto kolumny ['non flavonoid phenols', 'ash', 'proanthocyanidins', 'total phenols', 'alcalinity_of_ash', 'magnesium']

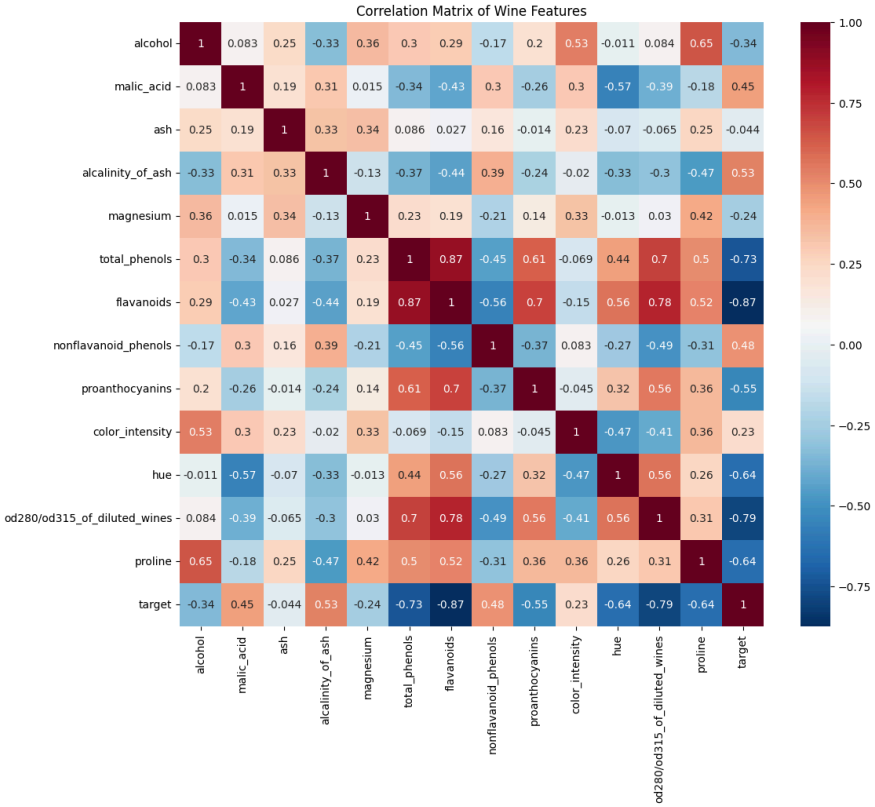
Correlation Matrix of Wine Features
alcohol 1 0.083 0.25 -0.33 0.36 0.3 0.29 -0.17 0.2 0.53 -0.011 0.084 0.65 -0.34
malic_acid 0.083 1 0.19 0.31 0.015 -0.34 -0.43 0.3 -0.26 0.3 -0.57 -0.39 -0.18 0.45
ash 0.25 0.19 1 0.33 0.34 0.086 0.027 0.16 -0.014 0.23 -0.07 -0.065 0.25 -0.044
alcalinity_of_ash -0.33 0.31 0.33 1 -0.13 -0.37 -0.44 0.39 -0.24 -0.02 -0.33 -0.3 -0.47 0.53
magnesium 0.36 0.015 0.34 -0.13 1 0.23 0.19 -0.21 0.14 0.33 -0.013 0.03 0.42 -0.24
total_phenols 0.3 -0.34 0.086 -0.37 0.23 1 0.87 -0.45 0.61 -0.069 0.44 0.7 0.5 -0.73
flavanoids 0.29 -0.43 0.027 -0.44 0.19 0.87 1 -0.56 0.7 -0.15 0.56 0.78 0.52 -0.87
nonflavanoid_phenols -0.17 0.3 0.16 0.39 -0.21 -0.45 -0.56 1 -0.37 0.083 -0.27 -0.49 -0.31 0.48
proanthocyanins 0.2 -0.26 -0.014 -0.24 0.14 0.61 0.7 -0.37 1 -0.045 0.32 0.56 0.36 -0.55
color_intensity 0.53 0.3 0.23 -0.02 0.33 -0.069 -0.15 0.083 -0.045 1 -0.47 -0.41 0.36 0.23
hue -0.011 -0.57 -0.07 -0.33 -0.013 0.44 0.56 -0.27 0.32 -0.47 1 0.56 0.26 -0.64
od280/od315_of_diluted_wines 0.084 -0.39 -0.065 -0.3 0.03 0.7 0.78 -0.49 0.56 -0.41 0.56 1 0.31 -0.79
proline 0.65 -0.18 0.25 -0.47 0.42 0.5 0.52 -0.31 0.36 0.36 0.26 0.31 1 -0.64
target -0.34 0.45 -0.044 0.53 -0.24 -0.73 -0.87 0.48 -0.55 0.23 -0.64 -0.79 -0.64 1
alcohol malic_acid ash alcalinity_of_ash magnesium total_phenols flavanoids nonflavanoid_phenols proanthocyanins color_intensity hue od280/od315_of_diluted_wines proline target
1.00 0.75 0.50 0.25 0.00 −0.25 −0.50 −0.75

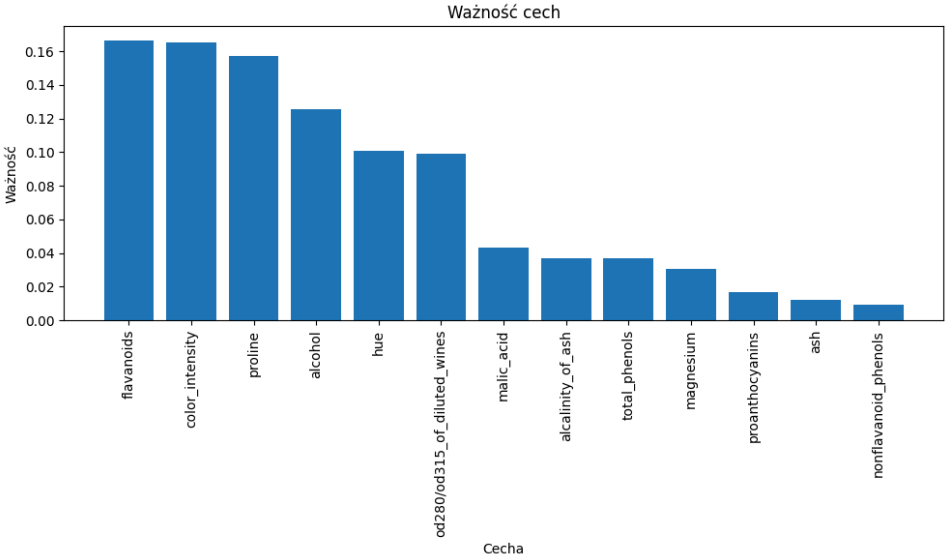
Ważność cech
Ważność
0.16 0.14 0.12 0.10 0.08 0.06 0.04 0.02 0.00
flavanoids
color_intensity
proline
alcohol
hue
od280/od315_of_diluted_wines
malic_acid
alcalinity_of_ash
total_phenols
magnesium
proanthocyanins
ash
nonflavanoid_phenols
Cecha

Zbiór Iris

Iris to popularny zbiór danych z biblioteki sklearn. Zbiór danych zawiera 3 klasy o 50 instancjach każda, gdzie każda klasa odnosi się do gatunku irysa. Zbiór danych zawiera 4 atrybuty: długość działki kielicha w cm, szerokość działki kielicha w cm, długość płatka w cm oraz szerokość płatka w cm.

Badana kolumna ‘target’ ma 3 klasy, dla których zachowana jest równowaga klasowa.

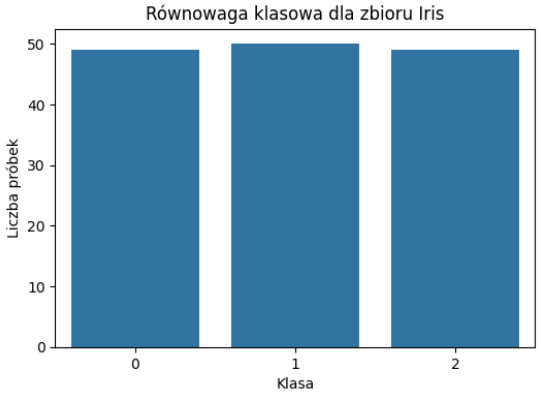

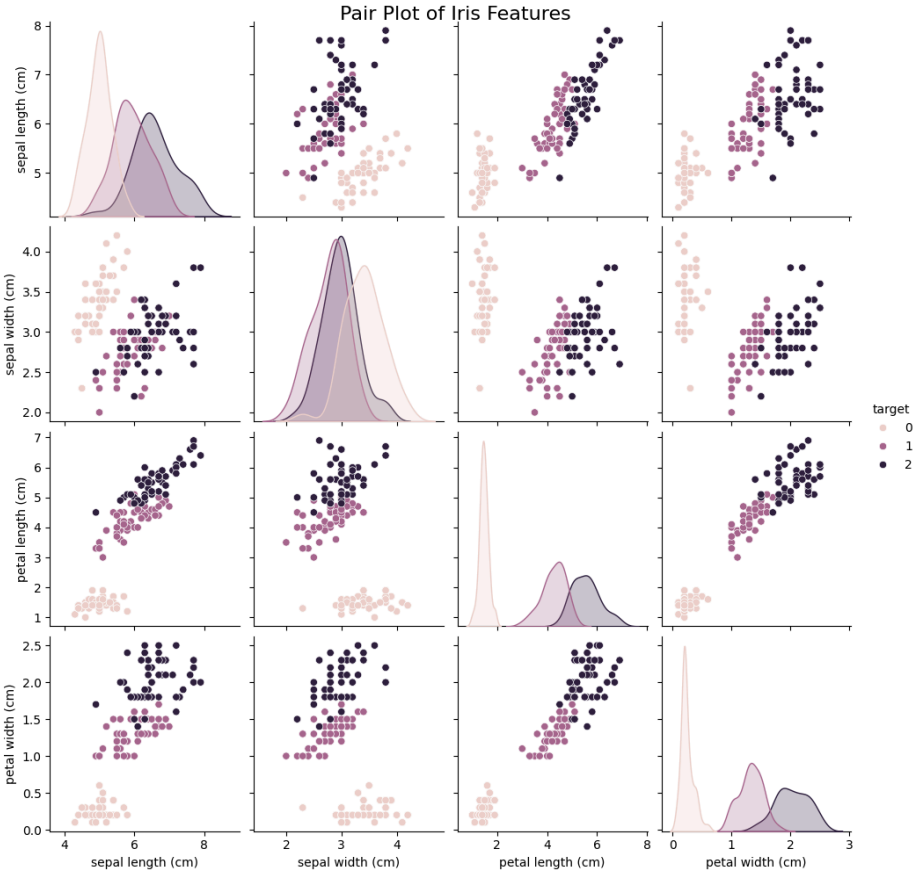

Zbiór iris - EDA

Podmieniono wartości NA na średnią kolumn funkcją do tego przeznaczoną. Usunięto duplikaty. Zamieniono próbki odstające (outliers) na średnią kolumn. Dokonano normalizacji - użyto skalera Standard Scaler z sklearn. Rozważałem nad usunięciem jednej z silnie skorelowanych cech (albo petal width albo height) - ale po ich usunięciu wydajność modelu spadła.

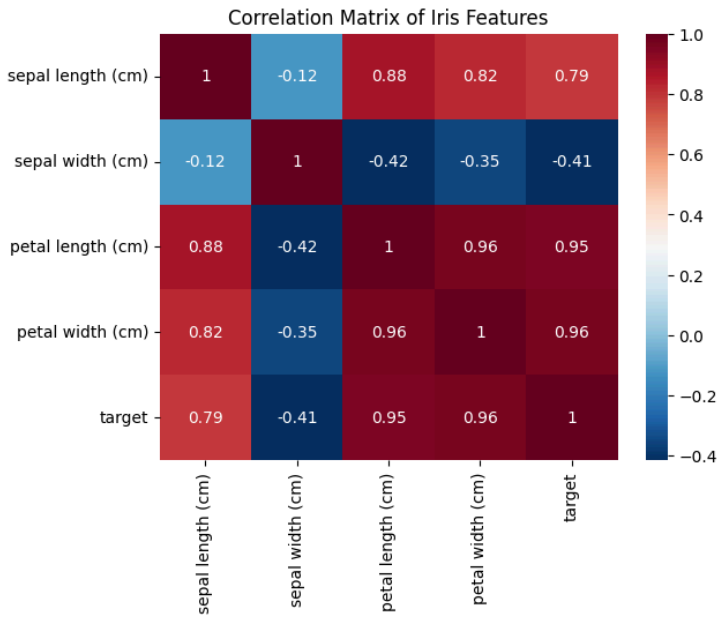

Zbiór Yelp Restaurant Reviews

“Yelp Restaurant Reviews” to zbiór danych zawierający recenzje restauracji i ich oceny (1-5 gwiazdek). Zawiera kolumny: Review Text (treść recenzji), Rating (ocena w gwiazdkach) i potencjalnie sentiment (zakodowany sentyment: -1 negatywny, 0 neutralny, 1 pozytywny). Jest duża nierównowaga klas z przewagą pozytywnych ocen co widać po wordcloud i wykresie równowagi klas. Zbiór danych jest duży - zawiera około 19,9K rekordów.

- Podmieniono etykiety na wartości liczbowe: -1 dla negatywnych, 0 dla neutralnych i 1 dla pozytywnych.
- Wyodrębniono tekst recenzji jako dane wejściowe.
- Dokonano tokenizacji i osadzenia (embedding) tekstu z gotowego modelu z hugging face

- Zastosowałem stemming (na drugim wordcloud)

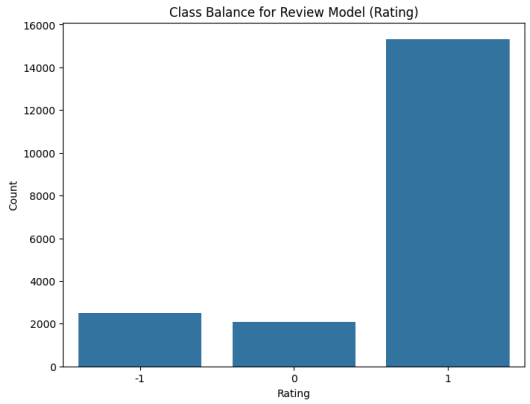

Wybór modelu do zbiorów danych (iris i wine)

K-means

- Zalety: Szybki, prosty w implementacji. Dobrze działa na danych o wyraźnych, kulistych klastrach.
- Wady: Wrażliwy na outliers, wymaga z góry określonej liczby klastrów.
- Oczekiwania: Na zbiorze iris powinien poradzić sobie bardzo dobrze ze względu na wyraźne rozdzielenie gatunków. Na zbiorze wine, który może mieć bardziej złożoną strukturę, może mieć problemy z wykryciem nietypowych klastrów.

Agglomerative

- Zalety: Buduje hierarchię klastrów, co pozwala na elastyczne podejście do wyboru liczby klastrów.

- Wady: Może być obliczeniowo kosztowny dla dużych zbiorów danych.
- Oczekiwania: Powinien dobrze poradzić sobie zarówno z iris, jak i Wine, szczególnie jeśli klastry mają różną gęstość.

DBSCAN

- Zalety: Dobry do wykrywania klastrów o dowolnym kształcie, odporny na outliers, dowolna liczba klastrów
- Wady: Wymaga dostrojenia dwóch parametrów (eps, min_samples), jest najbardziej obliczeniowo kosztowny
- Oczekiwania: Powinien dobrze poradzić sobie ze zbiorem wine, który może mieć nietypowe kształty klastrów. Na zbiorze iris również powinien dać dobre wyniki, ale może być nieco nadmiarowy.

Klasteryzacja zbioru Wine

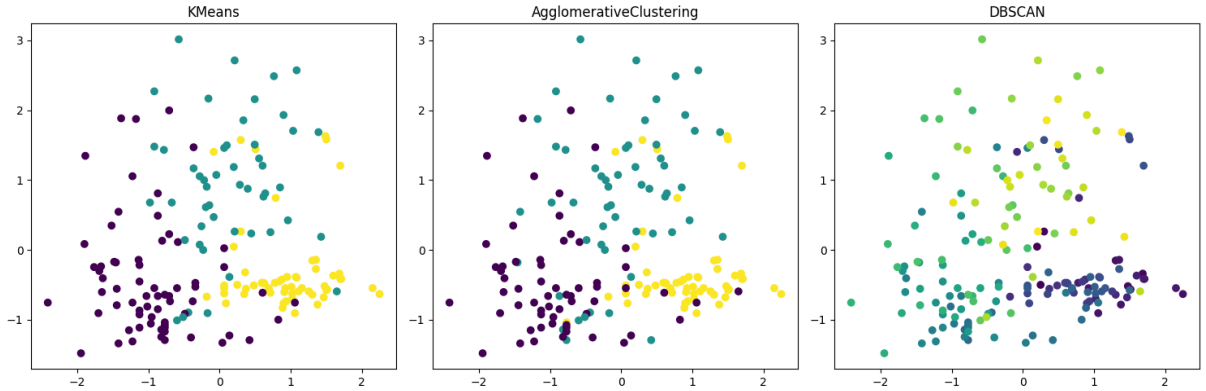

Klasteryzacja zbioru Iris

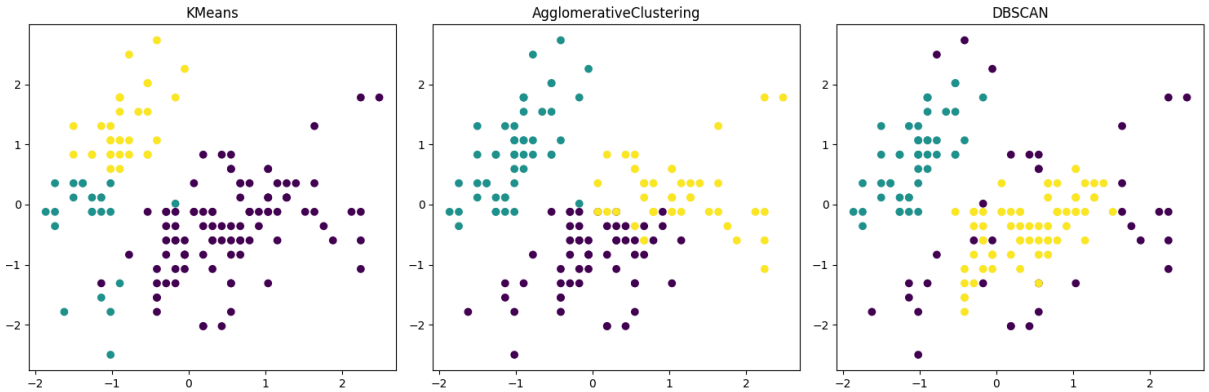

Klasteryzacja zbioru Restaurant Reviews.csv

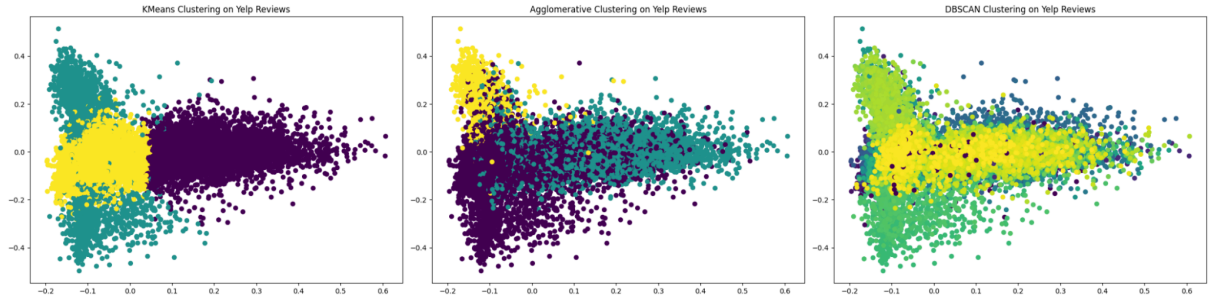

Wizualizacja granicy modelu Wine

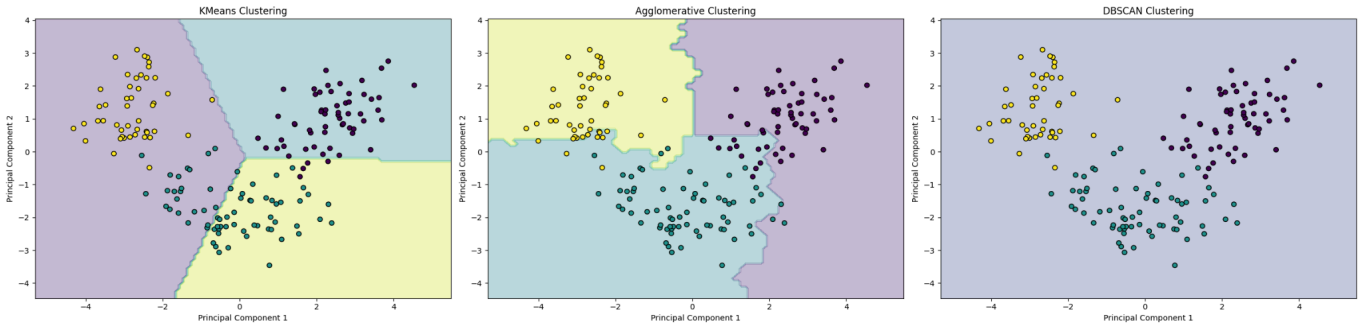

Wizualizacja granicy modelu Iris

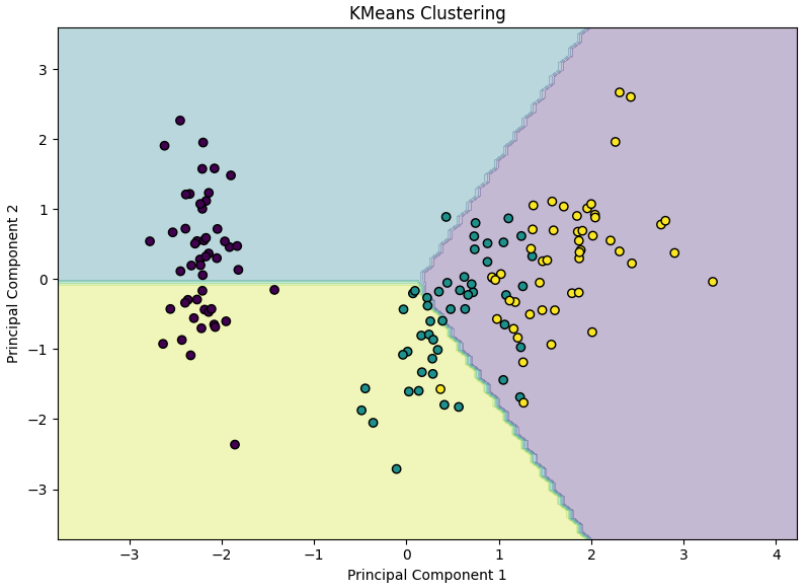

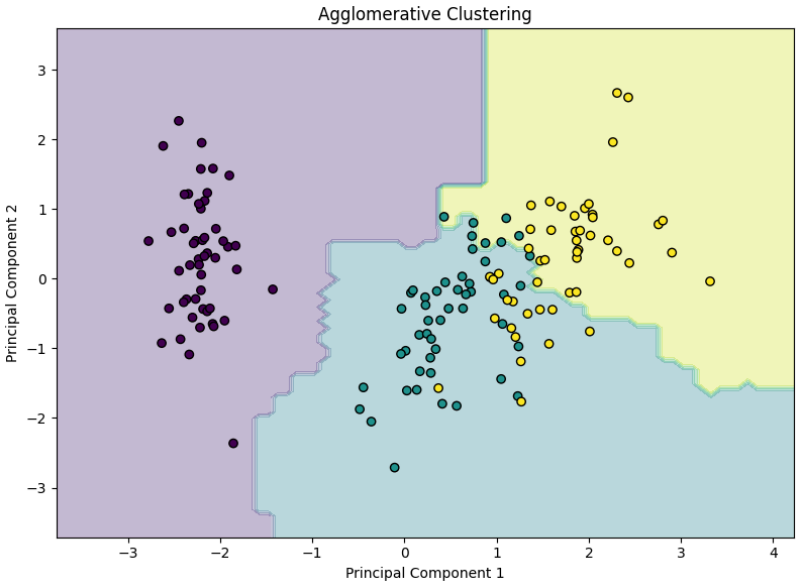

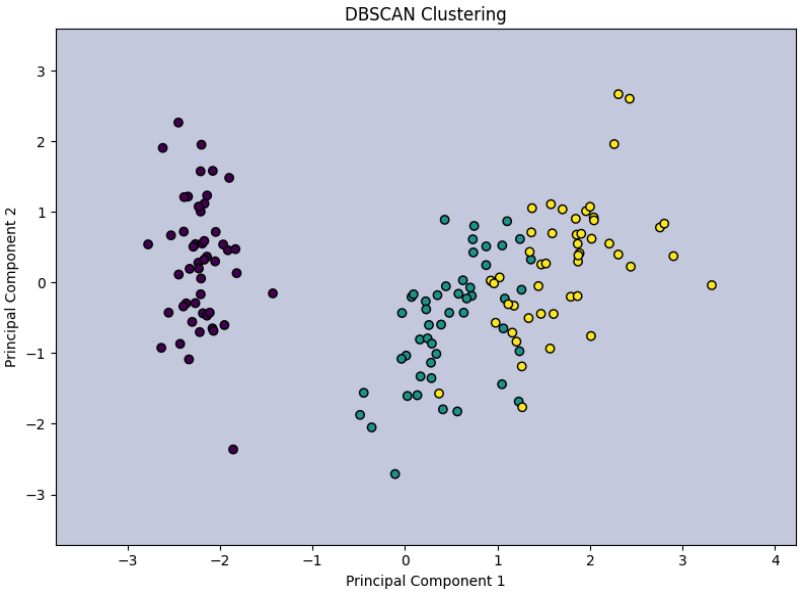

Wizualizacja granicy modelu Restaurant Reviews.csv

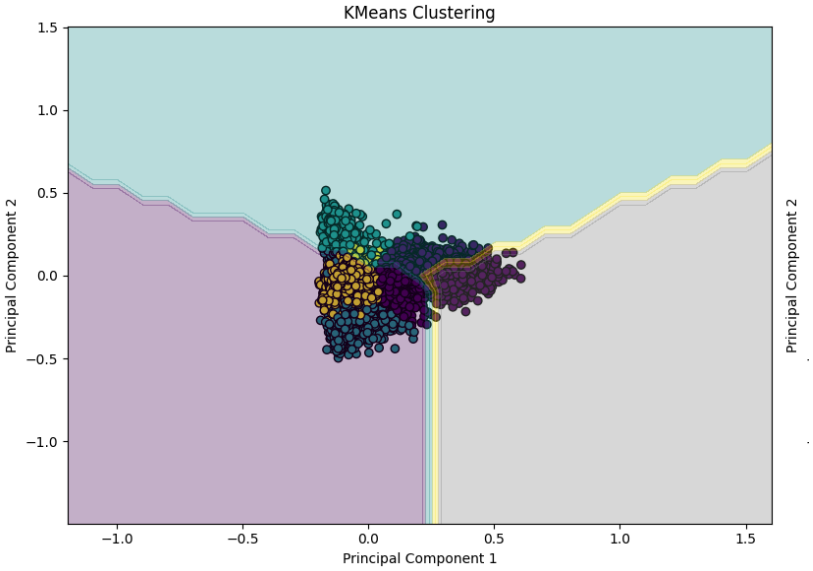

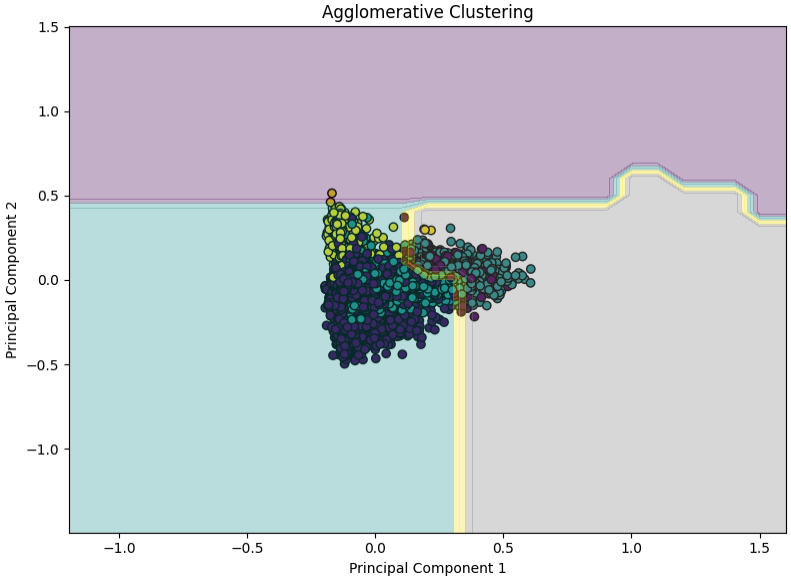

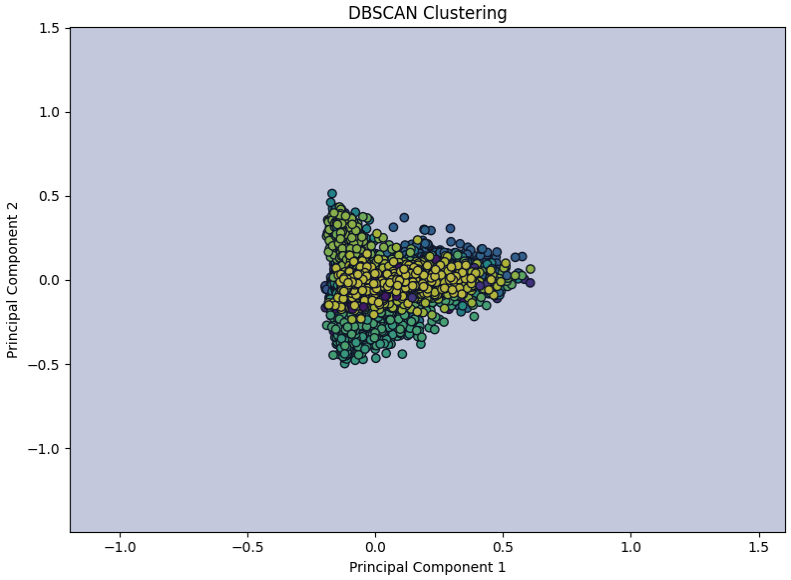

Efektywność modelu

Efektywność modelu Wine (KMeans,Agglo,DBSCAN):

Silhouette Score: 0.2898, 0.2782, 0.1661
Davies-Bouldin Score: 1.3467, 1.3981, 3.1816
Caliński-Harabasz Index: 73.924, 69.121, 30.173
dla parametrów modelu: k=3,eps=2.7,min samples=7

Jak interpretować wyniki?

Silhouette Score: Im bliższy 1, tym lepiej obiekty są przypisane do swoich klastrów. Wartości ujemne sugerują, że obiekt może być przypisany do niewłaściwego klastra.
Davies-Bouldin Score: Im niższa wartość, tym lepiej klastry są oddzielone.
Caliński-Harabasz Index: Im wyższa wartość, tym lepiej klastry są oddzielone i zwarte.

Efektywność modelu Iris (KMeans,Agglo,DBSCAN):

Silhouette Score: 0.4729, 0.4596, 0.3366
Davies-Bouldin Score: 0.8036, 0.8359, 14.529
Caliński-Harabasz Index: 153.08, 235.51, 85.545
dla parametrów modelu: k=3,eps=0.5,min samples=5

Efektywność modelu Yelp Reviews (KMeans,Agglo,DBSCAN):

Silhouette Score: 0.0145, 0.0068, 1.3108
Davies-Bouldin Score: 7.2410, 9.0130, 0.7121
Caliński-Harabasz Index: 236.79, 140.47, 1.9713
dla parametrów modelu: k=3,eps=0.9,min samples=1
dla parametrów wektoryzera TL-IDF: max_features=1000, stop_words='english'

Siatka parametrów dla każdego algorytmu

param_grid_kmeans = {'n_clusters': [3, 4, 5, 6]}
param_grid_agglomerative = {'n_clusters': [3, 4, 5, 6], 'linkage': ['ward', 'complete', 'average']}
param_grid_dbscan = {'eps': [0.3, 0.5, 0.7, 1.0], 'min_samples': [3, 5, 7]}
Dla algorytmów kmeans i agglomerative można zmienić liczbę klastrów na taka bardziej odpowiadająca faktycznej liczbie klastrów.
Dla algorytmu dbscan można zmienić linkage na avarage.

Najlepsze parametry Wine:

K-Means:
k-sąsiadów: 3

Agglomerative:
k-sąsiadów: 3
linkage: 'complete'

DBSCAN:
eps: 2.5
min_samples: 5

Najlepsze parametry Iris:

K-Means:
k-sąsiadów: 3

Agglomerative:
k-sąsiadów: 3
linkage: 'complete'

DBSCAN:
eps: 0.9
min_samples: 3